

ESTADÍSTICA E INFERENCIA I

Segundo Cuatrimestre — 2024

Segundo Parcial

APELLIDO Y NOMBRE:

Enviar todos los ejercicios en archivos separados aclarando en el nombre de cada uno **apellido y número de ejercicio**. La parte analítica en archivos pdf y la parte computacional en archivos ipynb.

1. Se modela Y , la cantidad de gotas por baldosa por minuto durante una lluvia, como una distribución de Poisson con parámetro θ . Es decir,

$$p(y|\theta) = \frac{e^{-\theta} \theta^y}{y!}$$

- (a) Demostrar que $\text{Gamma}(\alpha, \beta) = \frac{e^{-\beta\theta} \beta^\alpha \theta^{\alpha-1}}{\Gamma(\alpha)}$ es un prior conjugado para θ . ¿Qué distribución sigue la posterior? (Ayuda: obtener la distribución a menos de una constante de normalización)
- (b) Demostrar que si se realizan n observaciones $\{y_1, \dots, y_n\}$ (es decir, se mide la cantidad de gotas en una baldosa por minuto en n ocasiones distintas), la verosimilitud tiene la misma forma funcional que una distribución $\text{Gamma}(\sum_{i=1}^n y_i + 1, n)$. A partir de este resultado, ¿cómo se interpreta el prior conjugado en términos de resultados de hipotéticas observaciones poissonianas anteriores?
- (c) Se mide la cantidad de gotas caídas sobre una baldosa durante 5 minutos distintos y se obtienen los siguientes resultados: [104, 90, 81, 127, 98]. Se modela $Y \sim \text{Poisson}(\theta)$ y se propone un prior $\text{Gamma}(400, 5)$. Obtener la distribución posterior de θ , su esperanza y varianza posterior.

2. Sea $Y \sim \text{Bi}(n, \theta)$ con un prior conjugado para θ :

- (a) Construir una aproximación normal de $p(\theta|y)$ a partir de aproximar su logaritmo por una función cuadrática de θ . Explicitar la esperanza y varianza de la distribución normal obtenida como función de y, n y los hiperparámetros.
- (b) Se fija $n = 10$ y se eligen los hiperparámetros $\alpha = 3$ y $\beta = 2$. Para distintos valores de y , graficar y comparar la distribución obtenida con la distribución exacta y con la aproximación normal de momentos. ¿Cuál aproximación conviene cuando se tienen muy pocos (o muchos) éxitos? Demostrar gráficamente.

3. Un economista desea analizar los determinantes del salario utilizando un modelo lineal bayesiano. A partir del dataset `wage1.txt` (usa separador ‘\t’) se pide estimar el modelo:

$$\text{lwage} \sim \mathcal{N}(\mu, \sigma^2)$$

$$\mu = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{expersq} + \beta_4 \text{female}$$

Donde

- *lwage* es el logaritmo del salario de una persona,
- *educ* los años de educación recibida,
- *exper* sus años de experiencia en el mercado laboral,
- *expersq* su cuadrado, y
- *female* una variable dicotómica que toma el valor 1 cuando el individuo es una mujer.

Se pide:

- Definir y ajustar este modelo con PyMC, especificando los priors para los parámetros del modelo.
- Estimar la distribución posterior de los parámetros. Presentar la media y el intervalo de credibilidad al 95% (HDI) para cada parámetro e interpretar el resultado para β_4 .
- Basado en las distribuciones obtenidas, realizar una predicción para el salario de dos individuos con 3 años de experiencia laboral y 12 años de educación, uno de los cuales es hombre y el otro es mujer. Presentar ambas distribuciones en forma de histogramas y calcular el HDI 95%.
- Observando los traceplots de las figuras 1 y 2, ¿cuál muestra señales de convergencia de las cadenas y cuál no? En el caso del que no, ¿qué factores podrías considerar para mejorar la convergencia?
- Si decidieras utilizar un prior informativo para el parámetro β_1 ¿cómo seleccionarías un valor razonable? ¿En qué tipo de situaciones podría ser beneficioso usar un prior informativo en lugar de uno no informativo, y cómo afectaría esto los resultados de la regresión?




Figura 1:




Figura 2: